

Résultats expérimentaux

Scénarios Apprentissage

Continu

Sommaire

Modèles Supervisés (EWC, HDC, TinyOL)

Modèles Non Supervisés (Kmeans, Mahalanobis, DBSCAN)

Recap données

Pump Maintenance (2 scénarios: ID - Temporal Window)

Recap données

Equipment Monitoring (2 scénarios: Équipement - Location)

Meilleurs modèles pour Equipment Monitoring by Equipement

Modèles Supervisés _ EWC

Pénalisation de la modification des poids du réseau de neurones importants lors d'apprentissage de nouvelles tâches.

Stratégie : Accumulation

Garder Snapshot des poids et matrice de Fisher.

Fin de tâche nouvelle matrice fusionnée à l'ancienne.

-> Resume importance paramètres forme compacte.

Aucune donnée brute ou gradient individuel stocké.

Modèles Supervisés _ HDC

Encoder les entrées en hypervecteurs les comparer aux vecteurs type des classes.

Stratégie : Accumulation

Observation encodée en hypervecteur binaire , additionné au prototype de sa classe. Accumulateur INT32 non réinitialisé entre les tâches.

Aucune donnée brute , hypervecteur individuel stocké.

Modèles Supervisés _ TinyOL

Réseau de neurones pré entraîné gelé avec une couche adaptative.

Stratégie : Accumulation

Stocke les 10 poids dans OtO head

Stochastic Gradient Descent continu pas de reset entre les tâches.

MAJ poids continu a chaque sample peut importe la tâche.

Pas de buffer ou de snapshot

Modèles Non Supervisés _ Kmeans

Partition des données pour créer des groupes qui minimisent la variance

Stratégie : ReFit

Création nouveau modèle entraîné sur la nouvelle tâche.

On garde seulement le seuil établi lors de la tâche précédente.

Amélioration possible:

Adaptation de seuil dynamique : Exponential Moving Average (EMA)

Adapte graduellement le seuil selon les scores récents.

Biais vers les données normales récentes.

Modèles Non Supervisés _ Mahalanobis

Mesurer la distance d'un point X par rapport à une distribution pour déterminer si il est anormal.

Stratégie : ReFit

μ : le vecteur moyenne des features.

Σ^{-1} : l'inverse de la matrice de covariance

Amélioration possible:
algorithme de Welford

- mise à jour incrémentale de μ et Σ au lieu de les recalculer

Modèles Non Supervisés _ DBSCAN

Stratégie : ReFit


Partitionne les données en fonction de la densité des clusters.

Entraîné sur les données de la tâche courante seulement.

Recap données _ Pump Maintenance


	Pump_ID	Temperature	Vibration	Pressure	Flow_Rate	RPM	Operational_Hours	Maintenance_Flag
1	2	127.50835007924499	2.369396895708607	136.02102899159104	6.501491740898246	1444.191921586282	3966.793671846298	1
2	4	88.97518505816208	4.5411259135897115	147.51697269176566	7.0015162308093775	1004.8024957864203	3673.28893334156	0
3	3	61.83232457722971	2.5421119519830593	220.85857734400486	8.824368176356634	2597.662711715489	5489.061016489422	1
4	3	106.25034414465942	2.8344517828411053	145.81709102870565	16.2835115540096	2280.9262808792	3134.783014740251	0
5	2	84.81586512503186	3.119708650885018	235.47622143469835	8.385183024777913	2594.1316670984816	761.5331731185373	1
6	5	80.62222666258523	2.664719443583379	233.69640402433598	14.474800847811776	2430.0600859051424	1037.2719661979515	0
7	5	125.30045710284732	3.8243124645243087	193.28625379037118	2.073177316106293	1100.6240604578707	1795.1487963764914	1
8	3	77.05253829482919	2.6261505434039867	255.19930429040681	15.822936556288163	2378.030724567582	4250.459657034943	0
9	5	103.7374451603651	3.0357345781623217	285.82966149220294	3.802423632412188	2449.470978485251	1308.382479644153	1
10	1	73.91112330826448	2.963130352843897	251.455138065742	2.7103592640593535	2223.3785759134475	5967.585505617834	0
11	1	101.92091105987369	4.657018941249752	297.01502965827467	7.678913915140377	2525.997233953084	6437.3349824727975	1
12	2	99.49157885099778	4.559422688641461	266.1851543411684	14.274973568119806	2707.536977285571	8474.150455162879	1
13	1	74.15649754135863	4.337977884431758	228.5084957784754	12.363096006840017	2273.222648273242	3909.490985382435	0
14	3	129.33550990421577	2.9179266369539234	112.32093832149268	10.696780842281502	2977.0031799936933	2052.6432756887334	1
15	2	64.35114661103806	3.107607204196697	270.57655846564603	14.768302333537747	2152.5656987092634	8885.664295947827	0
16	4	51.24925603793113	0.3710062443622427	179.81716469807617	9.915315689129972	1505.192185180139	2339.7904634506463	1
17	5	146.53153082774338	4.121769718715721	285.37199058124577	2.23481628189674	2878.580489108441	9616.176859753956	0
18	4	101.1438057303281	2.94439219512034	186.61134342959275	16.801066941186267	1057.622169532417	8517.617748808962	1
19	2	85.00502733191084	2.725813480223959	207.9396359393883	9.855735200357493	2667.0883163453836	5096.102413722458	1
20	2	71.51282333429035	4.066965294576148	223.00856633620964	17.241511408835922	1299.725302857592	3260.2722644444557	0
21	4	134.38785476027797	3.8606968766239413	145.01902968631614	4.012986278475392	2359.5603208519233	5487.422673461793	1
22	1	109.69302649188913	4.209409002002021	264.32188091373916	1.9876261094093937	1539.7063014797877	7460.641430475168	1
23	5	87.92437406939888	4.506133948240729	100.4718022780638	15.515867524187875	1221.3403021150166	8757.780051869446	1

Recap données _ Pump Maintenance




Recap données _ Pump Maintenance

Boxplots par Pump_ID — Dataset 1



Recap données _ Pump Maintenance

Distribution par fenêtres d'Operational_Hours (5 bins) — Dataset 1




Pump Maintenance _ single task

Entraîner les modèles sur l'entièreté des données


Sans distinction de tâches

Pump Maintenance _ single task



Pump Maintenance _ single task

Matrices de confusion — 6 modèles (baseline single-task, Dataset 1 Pump)
Effectifs bruts




Pump Maintenance _ ID


Diviser données par ID de pompes

Entraîner progressivement les modèles sur les données ID par ID.

Pump Maintenance _ ID



Pump Maintenance _ ID




Pump Maintenance _ Temporal Window


Diviser données par fenêtres temporelles en fonction du nombre d'heures opérationnelles (Operational_Hours).

Entraîner progressivement les modèles sur les données fenêtre par fenêtre.

Accuracy finale par fenêtre temporelle — comparaison 6 modèles



Trade-off embarqué : RAM vs. performance CL (pump/by_temporal_window — Gap 2 STM32 ≤ 64 Ko)




Recap données _ Equipment Monitoring

	temperature	pressure	vibration	humidity	equipment	location	faulty
1	58.18018003931781	25.02927765103301	0.6065162172245139	45.694907104076414	Turbine	Atlanta	0.0
2	75.74071220894001	22.95401759548667	2.3380947537510077	41.867406792614915	Compressor	Chicago	0.0
3	71.35859424081657	27.27683031893662	1.3891983049086754	58.95440890948324	Turbine	San Francisco	0.0
4	71.61698526704753	32.24292130393475	1.7706896863176191	40.56513821185597	Pump	Atlanta	0.0
5	66.50683203881802	45.19747079743589	0.34539798929557564	43.253794756433095	Pump	New York	0.0
6	49.5109594501023	76.42672868018283	4.809297752752174	20.269692247772895	Compressor	New York	1.0
7	66.90350286011939	45.530758700156156	1.5483453514434098	64.8049215266908	Compressor	Houston	0.0
8	148.92336873207364	22.214121367591716	0.10981888071321333	39.944953294698905	Turbine	San Francisco	1.0
9	50.403298761202244	45.39989897809707	2.231717827130497	43.06766663283053	Pump	Houston	0.0
10	63.88614752611372	33.80291244598566	1.1392796250848973	41.795515332279166	Compressor	Atlanta	0.0
11	53.07043185804615	44.105202647740946	2.0716521371650067	47.45874176809897	Compressor	New York	0.0
12	141.26030984408388	54.23905839448483	2.7256907331768128	86.39046563060697	Pump	Atlanta	1.0
13	68.49162288433304	45.43867810655463	1.1950486465253989	59.989678353166205	Compressor	Houston	0.0
14	84.71170327493608	44.08496468393181	1.3594029939012853	47.56097051399158	Turbine	San Francisco	0.0
15	83.73658545162958	53.44757268774192	1.6430079038173124	25.5250485765034	Turbine	New York	0.0
16	81.66370545669253	21.75488511863934	1.2024155004624104	47.006730267041156	Compressor	Atlanta	0.0
17	67.41991463802391	31.181241132449326	1.4694021294460482	40.99360252021879	Compressor	New York	0.0
18	57.90305257158892	30.368126240480763	1.6529800122189182	48.857560858978744	Pump	Chicago	0.0
19	68.37207093927705	21.39498200278898	1.2247740636553939	47.37771862766168	Turbine	Atlanta	0.0
20	74.07052287124534	48.903879880988164	0.9233699136623706	50.287286924713044	Compressor	Atlanta	0.0


Recap données _ Equipment Monitoring

Boxplots par état (faulty) — Dataset 2 Equipment Monitoring




Boxplots par équipement et état (faulty) — Dataset 2

R



Boxplots par equipment × location — Dataset 2




Equipment Monitoring _ single task

Entraîner les modèles sur l'entièreté des données


Sans distinction de tâches

Equipment Monitoring _ single task



Equipment Monitoring _ single task

Matrices de confusion — 6 modèles (baseline single-task, Dataset 2 Monitoring)
Effectifs bruts




Equipment Monitoring _ Location


Diviser données par la provenance. tout équipement confondu mais séparé par emplacement (location)

Entraîner progressivement les modèles sur les données des cinq villes.


Accuracy finale par localisation — comparaison 6 modèles



Trade-off embarqué : RAM vs. performance CL
 (monitoring/by_location — Gap 2 STM32 $\leq$ 64 Ko) — DBSCAN dans budget



Trade-off coût calcul vs. performance CL (monitoring/by_location — MACs portable MCU)




Equipment Monitoring _ Equipement


Diviser données type d'équipement

Entraîner progressivement les modèles sur les données de pompes, turbines et compresseurs.


Accuracy finale par équipement — comparaison 6 modèles



**Trade-off embarqué : RAM vs. performance CL
(monitoring/by_equipment — Gap 2 STM32 $\leq$ 64 Ko)**











Trade-off coût calcul vs. performance CL (monitoring/by_equipment — MACs portable MCU)



Equipment Monitoring _ Equipement _ EWC


Equipme

Matrices de confusion — EWC (comptes bruts | seuil=0.5)




EWC — Évolution accuracy par tâche (monitoring/by_equipment)

Eq1



EWC — Espace features PCA 2D — by_equipment

Equip












Equipment Monitoring _ Equipement _ Mahalanobis


Equipme

Matrices de confusion — Mahalanobis (comptes bruts | seuil=0.5)


is



Mahalanobis — Évolution accuracy par tâche (monitoring/by_equipment)



Equip



Discussion

Lors d'un refit :

- Comment évaluer le volume de données nécessaire pour avoir un modèle performant?
- Comment la qualité des données influe sur ce volume?